

네이버 뉴스 크롤링 실습 보고서

– requests 시도부터 Selenium과 기사 상세페이지 활용까지 –

1. 실습 목적

본 실습의 목적은 네이버 뉴스에서 기사 제목과 이미지를 크롤링하는 것이다.

Python의 `requests` 라이브러리를 활용한 기본적인 크롤링부터 시작하여,

실습 과정에서 발생한 문제를 해결하기 위해 **Selenium**과 기사 상세페이지 접근 방식을 단계적으로 적용하였다.

본 보고서는 크롤링을 처음 배우는 입장에서

어떤 부분이 어려웠고, 왜 문제가 발생했는지, 이를 어떻게 해결했는지를 중심으로 정리하였다.

2. requests를 이용한 초기 크롤링 시도

2.1 시도한 방법

처음에는 비교적 간단한 방법이라고 생각하여 다음과 같은 방식으로 크롤링을 시도하였다.

- `requests` 와 `BeautifulSoup` 사용
- 네이버 뉴스 페이지에 직접 요청
- 기사 목록에서 제목과 이미지를 추출

이 방법은 다른 웹사이트에서는 정상적으로 동작했기 때문에 네이버 뉴스에서도 동일하게 사용할 수 있을 것이라 생각하였다.

2.2 발생한 문제

실제로 실행해본 결과 다음과 같은 문제가 발생하였다.

- 기사 목록이 정상적으로 나오지 않음
- 이미지가 존재하는 기사임에도 불구하고
코드상에서는 “이미지 없음”으로 출력됨
- 실행할 때마다 결과가 달라지는 현상 발생

이 과정에서 **웹페이지에서 보이는 내용과 requests로 받아온 HTML 구조가 다르다**는 점을 알게 되었다.

2.3 requests 방식의 한계 이해

조사해본 결과, 네이버 뉴스의 일부 페이지는

JavaScript를 통해 화면이 구성되는 구조를 사용하고 있었다.

이로 인해 requests로 HTML을 가져왔을 때:

- 실제 기사 정보가 포함되지 않거나
- 이미지 태그가 존재하지 않는 경우가 발생하였다.

이 단계에서 **requests만으로는 모든 네이버 뉴스 페이지를 크롤링하기 어렵다**는 점을 알게 되었다.

3. Selenium을 활용한 크롤링 시도

3.1 Selenium을 사용하게 된 이유

requests 방식의 한계를 보완하기 위해

실제 브라우저처럼 동작하는 Selenium을 사용해 보기로 하였다.

Selenium을 사용하면:

- 웹페이지가 실제로 로딩된 이후의 화면을 기준으로
- 요소를 선택할 수 있기 때문에

requests로 해결되지 않던 문제를 해결할 수 있을 것이라 판단하였다.

3.2 Selenium 적용 결과

Selenium을 사용하여 네이버 뉴스 **섹션 페이지**에 접근한 결과:

- 기사 목록이 정상적으로 수집됨
- 기사 제목과 썸네일 이미지 추출 가능

특히 뉴스 검색 페이지가 아닌

네이버 뉴스 섹션 페이지는 구조가 비교적 일정하여

Selenium으로 안정적인 크롤링이 가능하였다.

이 과정을 통해

페이지 선택이 크롤링 성공에 매우 중요하다는 점을 경험하였다.

4. Selenium 방식의 아쉬운 점

Selenium을 사용하여 크롤링에 성공하였지만,

다음과 같은 아쉬운 점도 있었다.

- 브라우저를 실행해야 하므로 코드가 다소 복잡해짐
- 단순한 데이터 수집 작업에 비해 설정이 많음

이로 인해 가능하다면 다시 **requests** 방식으로 돌아가고 싶다는 생각이 들었다.

5. 기사 상세페이지를 활용한 requests 크롤링

5.1 접근 방식 변경

앞선 경험을 바탕으로 접근 방식을 다음과 같이 변경하였다.

- 기사 목록 페이지는 구조가 안정적인 곳을 사용
- 실제 데이터 수집은 **기사 상세페이지**에서 수행

네이버 뉴스의 기사 상세페이지는

HTML 안에 기사 내용이 포함되어 있어

requests로도 비교적 안정적으로 처리할 수 있었다.

5.2 이미지가 나오지 않았던 이유

상세페이지에서도 처음에는

대부분의 기사에서 “이미지 없음”이 출력되었다.

확인해본 결과, 네이버 뉴스의 대표 이미지는

본문 안의 `<img>` 태그가 아니라

메타 태그(`og:image`)에 포함된 경우가 많았다.

이 점을 반영하여:

1. `og:image` 메타 태그에서 대표 이미지 확인
2. 없을 경우 본문 이미지 확인

하는 방식으로 코드를 수정하였다.

이후 이미지 수집이 정상적으로 이루어졌다.

6. 최종 구현 방식 정리

최종적으로 적용한 크롤링 흐름은 다음과 같다.

1. 네이버 뉴스 섹션 페이지에서 기사 목록 확인
2. 기사 제목과 상세페이지 URL 수집
3. requests로 기사 상세페이지 요청
4. 메타 태그(`og:image`) 기반 이미지 추출
5. 기사 정보 저장

이 방식은 실습용으로 이해하기 쉬우며,
앞선 문제점들을 대부분 해결할 수 있었다.

7. 실습을 통해 느낀 점

이번 실습을 통해

단순히 코드만 작성하는 것이 아니라

웹페이지의 구조와 동작 방식을 이해하는 것이 중요하다는 점을 알게 되었다.

처음에는 “코드가 잘못된 것 같다”고 생각했지만,

실제로는 **페이지 구조와 접근 방식의 차이**가 문제의 원인이었다.

이번 경험을 통해

크롤링은 한 가지 방법만 고집하기보다는

상황에 따라 적절한 방법을 선택해야 한다는 것을 배울 수 있었다.

8. 사용한 기술

- Python
- requests
- BeautifulSoup
- Selenium